

실시간 모의 선물 거래소

Binance 실시간 데이터 파이프라인

Binance USDS-M Futures의 실시간 호가창(order book)을 받아, 서버를 거쳐 모든 브라우저에 지연 없이 fan-out하는 reactive 파이프라인

Backend	Java 21 · Spring Boot 4 (WebFlux) · Reactor Netty · Jackson 3
Auth/DB	Spring Security · PostgreSQL (R2DBC)
Frontend	React + TypeScript (Vite) · TradingView Lightweight Charts
External	Binance USDS-M Futures — WebSocket (depth) · REST (kline)

이 문서의 범위


전체 프로젝트는 **호가창 → 차트 → 회원가입/로그인 → 호가창 기준 모의 주문 → 계좌·포지션·PnL**로 이어지는 학습용 모의 선물 거래소다. 이 문서는 그 중 모든 기능의 기준 가격 데이터를 만들어내는 **Binance 실시간 데이터 파이프라인** 파트만 다룬다. 주문 체결 엔진과 계좌/PnL 파트는 완성 후 별도 장으로 추가 예정.

왜 이 파트가 프로젝트의 핵심인가

- 호가창 표시, 캔들차트의 진행 봉, 모의 주문 체결가, 미실현 PnL까지 — 전부 이 파이프라인이 만드는 최신 호가 snapshot 하나를 기준값으로 동작한다.
- 외부 실시간 시스템(거래소 WebSocket) 연동, reactive 비동기 모델(cold/hot publisher), 락 없는 동시성 처리, 생명주기 분리 설계가 이 파트에 응축되어 있다.
- 직접 측정으로 원인을 좁힌 트러블슈팅 2건(중복 연결, 지역 차단)이 이 파트에서 나왔다 — 4페이지 참조.

GitHub: github.com/lee-gimoon · Sink Flow 인터랙티브 시각화: ([호스팅 링크](#) — 배포 후 기입) · 2026.06

아키텍처 — 호가 데이터가 흐르는 길



- 1. 부팅 시 1회 연결** @PostConstruct가 Binance WebSocket을 연결한다. 이후 브라우저가 몇 명 붙든 서버 ↔Binance 연결은 1개로 유지된다.
- 2. non-blocking 수신** Netty event loop가 100ms마다 도착하는 depth20 프레임(상위 20개 bid/ask)을 non-blocking으로 수신한다.
- 3. 파싱** raw JSON을 불변 record OrderBookSnapshot으로 변환한다. 가격·수량은 String → BigDecimal 직행.
- 4. 이중 발행** Store가 AtomicReference 교체(조회용)와 sink.tryEmitNext(push용)를 동시에 수행한다.
- 5. SSE push** /depth/stream 구독자 전원에게 즉시 push. 새로 접속한 브라우저는 replay(1)로 최신 1건을 바로 받아 빈 화면 없이 시작한다.
- 6. pull 조회** /depth/latest(디버깅용 단발 조회)뿐 아니라 모의 주문 API(POST /api/paper/orders)도 체결 직전에 AtomicReference에서 최신 snapshot을 꺼내 체결 기준 호가로 쓴다.

핵심 설계 결정

1. Binance 연결은 사용자가 아니라 서버가 소유한다

연결을 HTTP 요청이 아닌 **서버 생명주기**(@PostConstruct)에 묶었다. 1개여야 하는 upstream(서버↔Binance)과 N개여도 되는 downstream(브라우저↔서버)을 다른 트리거로 분리한 것. 브라우저가 전부 나가도 수신은 계속되고, 100명이 접속해도 Binance 연결은 1개다.

2. 폴링을 버리고 Hot Sink push로 전환

초기 구현은 `Flux.interval(100ms)`로 store를 폴링하고 `distinctUntilChanged`로 중복을 걸렀다. 이를 `Sinks.many().replay().limit(1)` 기반 push로 교체 — snapshot이 도착하는 순간 모든 구독자에게 전달되고, 빈 tick 낭비와 폴링 주기만큼의 지연이 사라졌다. 늦게 붙은 구독자도 `replay(1)`로 최신 1건을 즉시 받는다.

3. 락 없는 동시성 — AtomicReference + 불변 record

Writer는 WebSocket event loop 1개, Reader는 HTTP 요청 N개다. snapshot을 부분 수정하지 않고 매번 새 불변 record로 **통째 교체**하므로, synchronized 없이 AtomicReference의 원자적 참조 교체만으로 안전하다. 역할도 분리했다 — AtomicReference는 pull용(단발 조회 + 모의 주문의 체결 기준 snapshot 공급), Sink는 실시간 push용.

4. 가격은 String → BigDecimal 직행, double 금지

Binance가 가격을 "67000.10" 문자열로 보내는 이유는 이진 부동소수점 오차 때문이다. `asDouble()`을 거치면 그 시점에 이미 값이 망가지므로, `asString() → new BigDecimal(String)` 경로만 사용한다. 거래소에서 1원 오차는 누군가의 손익이다.

5. 메시지 단위 장애 격리

파싱 예외를 메시지 1건 단위로 잡아 warn 로그만 남기고 스트림은 계속 흐르게 했다. 깨진 메시지 하나가 실시간 파이프라인 전체를 죽이는 일을 막는다.

6. WebSocket 중계 대신 SSE, Tomcat 대신 WebFlux

서버→브라우저는 단방향 push라 SSE로 충분하다(EventSource 자동 재연결 포함). blocking MVC로 SSE를 구현하면 연결 100개에 worker thread 100개가 묶이지만, WebFlux/Netty event loop는 쓸 데이터가 생긴 순간에만 잠깐 write를 처리하므로 적은 스레드로 많은 SSE 연결을 유지한다.

트러블슈팅

1. 같은 Binance 스트림이 호출 수만큼 중복 연결되던 문제

증상	초기엔 프론트의 '스트림 시작' 버튼이 POST /raw/start로 connect()를 호출하는 구조였다. 버튼 재클릭·새로고침·새 탭마다 Binance WebSocket이 1개씩 늘어났고, 재연결이 아니라 같은 시간대에 N개가 나란히 살아서 동일 데이터의 수신 트래픽·로그·CPU가 N배가 됐다.
원인	webSocketClient.execute(...)가 반환하는 Mono는 cold publisher — subscribe할 때마다 새 연결을 만든다. 근본 원인은 1개여야 하는 upstream 연결의 생성을 N번 발생하는 downstream 트리거(사용자 행동)에 묶은 설계였다.
해결	connect()를 HTTP 엔드포인트에서 떼어내 @PostConstruct로 이동 — 빈 생성 직후 정확히 1회만 subscribe된다. 연결 수가 사용자 행동과 완전히 분리됐다.
배운 점	cold/hot publisher 구분이 '이 코드가 몇 번 실행되는가'를 결정한다는 것. 그리고 외부 연결의 소유권은 요청이 아니라 서버 생명주기에 뒤야 한다는 원칙.

2. WebSocket이 연결은 되는데 메시지가 0건 — 지역 차단 진단

증상	캔들차트용 @kline 스트림을 구독하면 에러 없이 연결되지만 메시지가 한 건도 오지 않았다. 예외도 로그도 없어서 코드만 보서는 원인을 알 수 없는 상태.
진단	스트림을 계열별로 분리해 수신 메시지 수를 직접 측정했다. 결과 — 체결 계열(@kline·@aggTrade·@markPrice)은 전부 0건 , 호가 계열(@depth·@bookTicker)과 REST API는 정상 . 동일한 코드·연결 방식에서 스트림 계열별로만 결과가 갈리므로, 코드 문제가 아니라 네트워크/지역 차단으로 원인을 분리했다.
해결	과거 봉은 Binance kline REST로 backfill(공개 시세라 API 키가 불필요 → 브라우저가 직접 호출), 진행 봉은 이미 백엔드가 받고 있는 호가 SSE의 best ask로 OHLC를 갱신. 추가 연결 0개로 차트를 완성했다.
배운 점	'안 된다'를 '정확히 무엇이 어디까지 되는가'로 좁히는 측정 기반 디버깅. 진행 봉이 체결가가 아닌 호가 기준이라는 한계는 숨기지 않고 문서에 명시했다.

현재 한계와 다음 단계

정직하게 적는 현재 한계

- **partial depth20 snapshot** — 정밀한 로컬 오더북이 아니다. Binance가 100ms마다 보내는 상위 20레벨을 통째로 교체할 뿐, sequence 검증이 없다.호가창 표시·간단한 모의 체결에는 충분하지만 정밀 체결 시뮬레이션에는 부족하다.
- **단일 서버 local fan-out** — 구독자 수백 명까지는 무난할 것으로 보지만, 1,000명 전후부터는 부하 테스트가 필요하다.
- **재연결·운영성 미구현** — 연결 끊김 시 지수 백오프 재연결, stale 호가 감지, health 표시는 거래 흐름(주문·계좌) 완성 후 불일 계획이다.

다음 단계 (로드맵 기준)

- **정밀 로컬 오더북** — REST snapshot + diff depth 스트림을 U/u/ps 필드로 sequence 검증하며 유지하고, 불일치 시 snapshot 재동기화. 현재의 SSE/화면은 그대로 두고 내부 source만 교체한다.
- **운영성 보강** — health 엔드포인트, 연결 status(UP/DOWN/STALE), 지수 백오프 재연결, 설정 외부화.
- **확장 설계** — 선직렬화(구독자 N명에게 같은 JSON을 N번 만들지 않기), throttle/diff 전송, 다중 인스턴스 시 브로커 도입 검토.

이 파트가 받치는 다음 기능들

이 파이프라인이 만드는 최신 호가 snapshot은 이후 단계의 기준값이 된다 — 모의 주문은 best bid/ask부터 호가 레벨을 순서대로 소진하며 체결되고(주문:체결 = 1:N), 미실현 PnL은 mid price로 계산된다. 즉 이 문서의 파이프라인이 거래소 전체의 '가격 진실 공급원(source of truth)'이다.

본 문서는 프로젝트 진행에 따라 업데이트됩니다. 주문 체결 엔진(PART 2), 계좌·포지션·PnL(PART 3) 추가 예정.